

UD1: PRÁCTICA 1

EVALUACIÓN DE PRESTACIONES MEDIANTE BENCHMARKING



INDICE

1.	INTE	RODUCCIÓN Y OBJETIVOS	2			
	1.1.	2				
	1.2.	OBJETIVOS	2			
2.	DES	ARROLLO	3			
	2.1.	SESIÓN 1: la Standard Performance Evaluation Corporation	3			
	2.1.1.	Significado de los benchmarks y los estimadores	3			
	2.2.	SESIÓN 2: Análisis cuantitativo de sistemas				
		Mediante los estimadores de SPEC				
	2.2.2.	Mediante los estimadores de NovaBench	<u>.</u>			
3.	CON	ICLUSIONES PERSONALES	11			
4.	BIBLIOGRAFÍA1					



1. INTRODUCCIÓN Y OBJETIVOS

1.1. INTRODUCCIÓN

La evaluación del rendimiento de los sistemas informáticos es una tarea crítica para comprender y optimizar el funcionamiento de las computadoras. Los programas de benchmark desempeñan un papel fundamental en este proceso al proporcionar métricas que permiten comparar y medir el desempeño de diversos equipos bajo condiciones controladas y estandarizadas. Esto se logra al someter a cada sistema a una carga de trabajo idéntica, lo que garantiza que las estimaciones sean comparables entre sí.

1.2. OBJETIVOS

-Aprender a comparar las prestaciones ofrecidas por distintos equipos informáticos: El objetivo principal de este trabajo es adquirir las habilidades necesarias para evaluar y comparar el rendimiento de sistemas informáticos. A través de la utilización de benchmarks, exploraremos cómo medir y cuantificar el desempeño de hardware y software en una variedad de contextos.

-Aprender a elegir el mejor equipo informático para resolver tareas específicas: No todos los sistemas informáticos son iguales, y su rendimiento puede variar significativamente en función de sus características y capacidades. Al comprender cómo utilizar benchmarks para evaluar el rendimiento, aprenderemos a seleccionar el equipo más adecuado para abordar tareas específicas, optimizando así la inversión en tecnología y mejorando la eficiencia en diversos escenarios de aplicación.



2. DESARROLLO

2.1. SESIÓN 1: la Standard Performance Evaluation Corporation

Los benchmarks son programas esenciales utilizados para medir y evaluar el rendimiento de sistemas informáticos o sus componentes individuales. En el contexto de la evaluación de rendimiento de las CPUs, la Standard Performance Evaluation Corporation (SPEC) proporciona una valiosa fuente de métricas y benchmarks que permiten comparar y comprender el desempeño de una amplia gama de sistemas informáticos. SPEC, con su sitio web (www.spec.org), ofrece información actualizada y trimestral sobre sus benchmarks y los resultados obtenidos a través de ellos. En este desarrollo, nos centraremos en cuatro suites de benchmarks específicos diseñados para evaluar el rendimiento de la unidad central de procesamiento (CPU).

2.1.1. Significado de los benchmarks y los estimadores.

Antes de empezar el análisis cuantitativo, respondemos una serie de preguntas sobre la web de SPEC→ Overview / What's New?)

1. ¿Cuál es la diferencia entre un benchmark y una suite (de benchmarks)?

Un benchmark es un programa o prueba específica utilizada para medir el rendimiento de un sistema o componente. En contraste, una suite de benchmarks es un conjunto de varias pruebas o benchmarks diseñados para evaluar diferentes aspectos del rendimiento de un sistema. Mientras que un benchmark se centra en una sola métrica, una suite de benchmarks abarca múltiples pruebas para una evaluación más completa.

2. ¿Cuántas suites de benchmarks se incluyen en la especificación SPEC CPU2017 y cómo se organizan?

La especificación SPEC CPU2017 incluye cuatro suites de benchmarks. Estas suites se organizan en dos categorías: 'speed' (velocidad) y 'rate' (tasa). Cada categoría contiene dos suites: SPECspeed 2017 Integer y SPECspeed 2017 Floating Point en la categoría 'speed', y SPECrate 2017 Integer y SPECrate 2017 Floating Point en la categoría 'rate'.

3. ¿Qué diferencia hay entre los benchmarks de 'speed' y los benchmarks de 'rate'?

Los benchmarks de 'speed' miden el tiempo que una CPU tarda en completar una tarea específica. Los benchmarks de 'rate' evalúan cuántas tareas de la misma categoría (ya sea enteros o coma flotante) una CPU puede realizar en un tiempo fijo, por tanto estas últimas evalúan el rendimiento.

4. ¿Qué dos tipos de benchmarks de 'speed' y de 'rate' se ejecutan para la obtención de métricas en la CPU? ¿Y por qué dos tipos?

Para obtener métricas de rendimiento en la CPU, se ejecutan dos tipos de benchmarks en las categorías 'speed' y 'rate'. En 'speed', se ejecutan SPECspeed 2017 Integer y SPECspeed 2017 Floating Point, y en 'rate', se ejecutan SPECrate 2017 Integer y SPECrate 2017 Floating Point. Se utilizan dos tipos para evaluar tanto el rendimiento en operaciones con enteros como en operaciones en coma flotante, ya que ambas son esenciales en diferentes aplicaciones y cargas de trabajo.

5. ¿Cómo se obtienen los ratios para los benchmarks de 'speed'?



Los ratios para los benchmarks de 'speed' se obtienen comparando el tiempo de ejecución de la máquina de referencia con el tiempo de ejecución de la CPU evaluada. El ratio se calcula dividiendo el tiempo de referencia por el tiempo de ejecución de la CPU.

6. ¿Y cómo se obtienen los ratios para los benchmarks de 'rate'?

Los ratios para los benchmarks de 'rate' se obtienen comparando la tasa de ejecución de la máquina de referencia con la tasa de ejecución de la CPU evaluada. El ratio se calcula dividiendo la tasa de referencia por la tasa de ejecución de la CPU.

7. ¿Qué significan las siglas SUT?

Las siglas "SUT" representan "System Under Test" o "Sistema en Evaluación". Se refieren al sistema o componente informático que se está evaluando o sometiendo a pruebas en un benchmark.

8. ¿En cuanto a la forma de calcularlas, qué diferencia hay entre las métricas de base 'base metrics' y las métricas de pico 'peak metrics'?

Las métricas de base ('base metrics') se calculan utilizando resultados de referencias de una sola ejecución, lo que refleja un rendimiento más realista. Las métricas de pico ('peak metrics') se calculan utilizando los mejores resultados de varias ejecuciones de referencia, lo que refleja el rendimiento máximo teórico del sistema.

9. ¿En cuanto al significado del estimador, en qué unidades se expresan las métricas de base 'base metrics' y las métricas de pico 'peak metrics'?

Las métricas de base y pico se expresan en unidades específicas para cada benchmark. Las unidades pueden variar según el tipo de prueba, como operaciones por segundo, tiempo (segundos) o una unidad adimensional, según la métrica específica.

10. Para la tabla de resultados de una CPU evaluada con SPEC CPU2017 (ver imagen), ¿cómo se obtiene el estimador de 'ratio' a partir de la medida real (tiempo) obtenida de la ejecución del benchmark? Fíjate que cada benchmark se ejecuta 3 veces (3 columnas en la tabla) obteniendo para cada vez (para cada columna) 2 medidas: una de tiempo (en s) y un ratio (adimensional)

Para calcular el estimador de 'ratio' en la tabla de resultados de una CPU evaluada con SPEC CPU2017, se divide el tiempo de ejecución real del benchmark por el tiempo de ejecución de la máquina de referencia. El resultado de esta división se presenta como el ratio en la tabla. Esta operación se realiza para cada ejecución del benchmark, que se repite tres veces.

11. De nuevo para la misma tabla de resultados, ¿por qué piensas que cada prueba se ejecuta tres veces y no una sola?

Cada prueba se ejecuta tres veces para obtener resultados más confiables y reducir el impacto de las variaciones aleatorias en el rendimiento. Tomar el promedio de estas ejecuciones mejora la precisión de las métricas.

12. ¿Se utiliza la misma máquina de referencia para los benchmarks de SPEC de 2006 y los de 2017? Si no es así, ¿qué máquina se utiliza en cada caso? ¿Por qué crees que se utilizan máquinas diferentes?

No se utiliza la misma máquina de referencia para los benchmarks de SPEC de 2006 y los de 2017. La SPEC de 2006 se utilizaba el UltraSPARC II de 300 MHz de 1997, mientras que en SPEC 2017 se utiliza el Sun Fire V490 con chips UltraSPARC-IV+ de 2100 MHz.

13. ¿Crees que sería posible convertir los resultados de la suite SPEC 2006 a la nueva suite SPEC 2017 para no tener que repetir los benchmarks sobre las máquinas evaluadas en 2006?



No sería posible convertir directamente los resultados de la suite SPEC 2006 a la suite SPEC 2017, ya que estas suites tienen configuraciones y métricas diferentes. Cada versión de SPEC tiene sus propias métricas y configuraciones específicas, por lo que los resultados no son directamente comparables. La puntuación del 2006 viene de un escenario distinto (copias, 8 núcleos, 4 chips; frente al escenario de referencia de 1 copia, 1 núcleo, 1 chip).

14. Con la herramienta de búsqueda avanzada de SPEC y para la sección de TODOS los resultados, localiza los resultados de los benchmarks de la máquina de referencia (Sun Fire V490, de Sun Microsystems). Para la ejecución de cada uno de los programas que componen este benchmark, ¿qué valores de 'ratio' proporciona esta misma máquina y por qué?

Los valores de 'ratio' reflejan el rendimiento de la máquina de referencia en comparación consigo misma y se utilizan como punto de referencia para comparar otras máquinas. Pero como la estamos comparando con ella misma el ratio sale 1.

15. Ahora, para la tabla de resultados de una CPU en concreto (ver imagen inferior), ¿por qué se realizan tres ejecuciones del mismo test? ¿Cuál de los tres resultados se escoge para el cálculo del estimador final?

Se realizan tres ejecuciones del mismo test para obtener una muestra de rendimiento más sólida y confiable. Por lo general, se selecciona la mediana (el de valor intermedio).

16. De nuevo para la tabla de resultados de una CPU en concreto (ver imagen inferior), ¿qué cálculo matemático se realiza para la obtención del estimador de base y el estimador de pico? Calcula ambos estimadores a partir de los ratios mostrados en la tabla. Comprueba que, efectivamente, el estimador de base vale 10,6 y el de pico 10,8.

Para calcular los estimadores de base y pico a partir de la tabla de resultados de una CPU específica en SPEC CPU2017, se sigue el siguiente procedimiento:

Para el estimador de base, se toman los tres valores calculados para cada uno de los 10 programas y se encuentra la mediana de estos valores. Luego, se calcula la media geométrica de las 10 medianas, lo que implica calcular la raíz décima del producto de estos 10 valores. El resultado redondeado es 10,6.

Para el estimador de pico, se sigue un proceso similar, pero esta vez se utilizan los valores de la parte azul de los resultados que indican "peak". Siguiendo el mismo cálculo, el resultado redondeado es 10,8.

Realizando el calculo tenemos que:

Base=10,56 que se redondea al resultado 10,6.



Peak=10,76 que se redondea al resultado 10,8.

J **SPEC® CPU2017 Integer Speed Result** Copyright 2017-2019 Standard Performance Evaluation Corporation ASUSTeK Computer Inc. SPECspeed2017_int_base = 10.6 ASUS RS300-E10(P11C-C/4L) Server System SPECspeed2017_int_peak = 10.8 (3.50 GHz, Intel Xeon E-2134) CPU2017 License: 9016 Test Date: May-2019 ASUSTeK Computer Inc. Hardware Availability: Dec-2018 Test Sponsor: Tested by: ASUSTeK Computer Inc Software Availability: Nov-2018

Benchmark result graphs are available in the PDF report.

Hardware Software Intel Xeon E-2134 SUSE Linux Enterprise Server 12 (x86_64) SP3 Kernel 4.4.120-94.17-default CPU Name: OS: Max MHz.: 4500 C/C++: Version 19.0.1.144 of Intel C/C++ Compiler: Nominal: 3500 Compiler Build 20181018 for Linux Enabled: 4 cores, 1 chip, 2 threads/core Fortran: Version 19.0.1.144 of Intel Fortran Orderable: 1 chip Compiler Build 20181018 for Linux Cache L1: 32 KB I + 32 KB D on chip per core Parallel: Yes L2: 256 KB I+D on chip per core Version 0502 released Nov-2018 Firmware: L3: 8 MB I+D on chip per chip File System: btrfs Other: System State: Run level 3 (multi-user) 64 GB (4 x 16 GB 2Rx8 PC4-2666V-E) Memory: Base Pointers: 64-bit 1 x 500 GB SATA HDD, 7200RPM Storage: Peak Pointers: 64-bit Other: None Other: jemalloc: jemalloc memory allocator library V5.0.1 **Results Table** Base Peak Benchmark Seconds Ratio Seconds Ratio Seconds Ratio Ratio Threads Seconds Ratio Seconds Ratio Seconds 600.perlbench_s 205 8.6 205 8.6 206 8.63 242 7.3 241 7.3 12.2 602.gcc_s 336 11.9 327 326 337 11.8 336 11.9 12.2 327 12.2 605.mcf_s 15.5 303 15.6 303 15.6 304 15.5 304 304 15.5 302 15.6 620.omnetpp_s 225 226 224 231 228 226 7.2 7.2 7.2 7.2 7.0 7.1 623.xalancbmk_s 97.1 96.9 14.6 96.7 98.0 97.4 14.6 97.0 14.7 14.5 14.6 14.6 104 104 625.x264_s 17.0 104 17.0 104 17.0 104 17.0 17.0 104 **17.0** 631.deepsjeng_s 220 220 6.5 221 6.50 220 6.51 220 6.5 6.5 220 6.5 641.leela_s 316 315 315 315 5.4 5.40 314 5.43 5.4 5.42 315 5.4 648.exchange2_s 16.3 16.1 181 16.2 181 16.3 182 16.2 183 181 181 16.2

17. a partir de los estimadores para el benchmark de 'FP speed' que se muestran en la siguiente figura explica el procedimiento para identificar la máquina a la que corresponden (para la herramienta de búsqueda avanzada de SPEC, el estimador de pico se determina en el campo 'Peak Result' y el de base en el campo 'Base Result'). Aplica el procedimiento para calcular los estimadores de pico y base identificando finalmente a qué máquina pertenecen los resultados de la figura (para afinar la búsqueda deberás redondear los estimadores obtenidos al entero más próximo).

501 12.3

Results appear in the order in which they were run. Bold underlined text indicates a median measurement

489 12.6

489 12.6

489 12.6

Velocidad base=215,357 redondeamos al entero 215

503 12.3

10.6

SPECspeed2017_int_base

SPECspeed2017_int_peak 10.8

<u>501</u>

Velocidad peak=217,627 redondeamos al entero 218

Y nos sale que es el Intel S9256WK1HLC

657.xz_s



Results Table														
Benchmark	Base					Peak								
Dencimark	Threads	Seconds	Ratio	Seconds	Ratio	Seconds	Ratio	Threads	Seconds	Ratio	Seconds	Ratio	Seconds	Ratio
603.bwaves_s	112	73.8	<u>799</u>	72.5	813	73.9	798	112	73.5	803	75.1	786	74.8	789
607.cactuBSSN_s	112	69.5	240	69.4	240	70.0	238	112	69.8	239	69.7	239	69.0	241
619.lbm_s	112	36.6	143	37.5	140	36.2	145	112	32.7	160	45.0	116	35.3	148
621.wrf_s	112	89.1	148	89.2	148	89.5	148	112	88.0	150	88.1	150	88.6	149
627.cam4_s	112	49.7	178	49.2	180	48.8	181	112	48.8	181	48.7	182	48.8	182
628.pop2_s	112	<u>171</u>	69.4	171	69.5	174	68.1	112	172	69.1	<u>170</u>	69.9	170	70.0
638.imagick_s	112	52.5	275	53.3	270	53.1	272	112	53.0	272	53.3	271	52.5	275
644.nab_s	112	38.4	455	38.4	455	38.4	455	112	38.0	460	38.4	455	38.3	456
649.fotonik3d_s	112	81.0	113	80.2	<u>114</u>	79.8	114	112	78.0	117	79.3	115	78.8	116
654.roms_s	112	54.2	290	52.5	<u>300</u>	51.5	305	112	50.7	<u>311</u>	53.3	296	50.6	311

2.2. SESIÓN 2: Análisis cuantitativo de sistemas

A continuación, estudiaremos cuantitativamente las prestaciones de los sistemas propuestos. Para ello utilizarás tanto los estimadores publicados por la Standard Performance Evaluation Corporation (SPEC) en su web como los estimadores obtenidos con el benchmark de Novabench.

2.2.1. Mediante los estimadores de SPEC

Ahora pasaremos a analizar los resultados publicados en SPEC CPU 2017, estableciendo una comparativa entre los sistemas que mejores prestaciones nos ofrecen, para la suite de benchmarks para velocidad de la CPU y procesamiento numerico en coma flotante sobre tres de las marcas comerciales propuestas: ASUSTek, Dell, Fujitsu. Son sistemas de un solo chip con cuatro cores de procesamiento. Utilizando el buscador avanzado que nos ofrece la web:

ASUSTEK ASUS RS300- 36.8 36.2 - - 4 1 Feb- HTML CSV PDF PS Text Config

Computer E11(P12R-M) Server -- 2022

Inc. System (3.70 GHz,

Intel Xeon E-2374G)

Dell Inc. PowerEdge T350 (Intel 35.0 34.2 - - 4 1 Oct- HTML CSV PDF PS Text Config

Xeon E-2374G, 3.70 -- 2021

GHz)

Fujitsu PRIMERGY TX1330 M5, Intel - 34.7 - - 4 1 Mar- HTML CSV PDF PS Text Config Xeon E-2374G, 3.70GHz - - - 2022

PRIMER EQUIPO

-Marca comercial (en el filtro 'Hardware Vendor'): ASUSTeK Computer Inc

-Nombre del sistema: ASUS RS300-E11(P12R-M) Server System

-Procesador: Intel Xeon E-2374G

-Velocidad de procesamiento (GHz): 3.70 GHz

-Cores y chips: 4 Cores, 1 Chips.

-Result (estimador de pico): 36.8

-Baseline (estimador de base): 36.2



-Fecha del test (Published): Feb-2022

SEGUNDO EQUIPO

-Marca comercial (en el filtro 'Hardware Vendor'): Dell Inc.

-Nombre del sistema: PowerEdge T350

-Procesador: Intel Xeon E-2374G

-Velocidad de procesamiento (GHz): 3.70 GHz

-Cores y chips: 4 Cores, 1 Chips.

-Result (estimador de pico): 35.0

-Baseline (estimador de base): 34.2

-Fecha del test (Published): Oct-2021

TERCER EQUIPO

-Marca comercial (en el filtro 'Hardware Vendor'): PRIMERGY TX1330 M5

-Nombre del sistema: ASUS RS300-E11(P12R-M) Server System

-Procesador: Intel Xeon E-2374G

-Velocidad de procesamiento (GHz): 3.70 GHz

-Cores y chips: 4 Cores, 1 Chips.

-Result (estimador de pico):

-Baseline (estimador de base): 34.7

-Fecha del test (Published): Mar-2022

En esta comparativa, el sistema de ASUSTeK Computer Inc. obtiene el estimador tanto de base como de pico más alto, por tanto, podríamos decir que es la opción que nos proporciona un mejor rendimiento, será la opción que elijamos.



2.2.2. Mediante los estimadores de NovaBench

Este apartado de la práctica consiste en la ejecución real de un benchmark sobre el sistema que estoy utilizando en el laboratorio.

novabench score



macOS 13.5

Overview Q Online Comparison Advisor

CPU Score



GPU Score



Apple M2

• •

3.5 GHz

Peak workload

Clock Speed

SIMD 1014 GFLOPS

Varied workload

Compression 778 MB/s Cryptography 8070 MH/s Apple M2

Workload

Metal 3D 31 FPS Compute 3718 GFLOPS

Memory transfer

On-device 84734 MB/s Host to device 78246 MB/s

Memory Score



Storage Score



16GB LPDDR5

Apple SSD AP0256Z

Transfer	Write	
Peak speed	38482 MB/s	Sequent

Access

Latency 95 ns

Sequential 3658 MB/s
Random 684 MB/s
Read
Sequential 3671 MB/s

Sequential 3671 MB/s Random 142 MB/s

¿cuál es el score general de la máquina analizada del benchmark de Novabench?, ¿en qué
posición relativa (cuartil) se encuentra respecto de TODOS los sistemas testeados y
publicados en la web de Novabench (utiliza para ello el estimador general etiquetado
como 'Novabench score')?

El score general de la máquina analizada del benchmark de Novabench es de 1887, que estaría ubicado en la posición 2419 de los 4029 resultados que nos proporciona Novabench en su estimador general (Top User Results).



Dado que su posición relativa sería el percentil 60, se puede decir que esta máquina se encuentra en el tercer cuartil, ya que se encuentra por encima del percentil 50, lo que significa que está por debajo de la mediana en términos de rendimiento según el estimador 'Novabench score'.

2. ¿qué estimador (valor y unidades) proporciona NovaBench para evaluar las prestaciones del sistema en operaciones de coma flotante?, ¿cuál sería su equivalente en SPEC (valor y unidades)?

NovaBench proporciona un estimador llamado "NovaBench Floating Point Score" para evaluar las prestaciones del sistema en operaciones de coma flotante. Este valor se expresa en puntos NovaBench. El equivalente en SPEC sería el estimador "SPECrate 2017 Floating Point." Ambos estimadores miden el rendimiento en operaciones de coma flotante, pero utilizan escalas y unidades diferentes.

3. ¿qué estimador (valor y unidades) proporciona NovaBench para evaluar las prestaciones del sistema en operaciones sobre enteros?, ¿cuál sería su equivalente en SPEC (valor y unidades)?

NovaBench proporciona un estimador llamado "NovaBench Integer Score" para evaluar las prestaciones del sistema en operaciones sobre enteros. Este valor se expresa en puntos NovaBench. El equivalente en SPEC sería el estimador "SPECrate 2017 Integer." Al igual que en el caso de las operaciones de coma flotante, ambos estimadores miden el rendimiento en operaciones sobre enteros, pero utilizan escalas y unidades diferentes.

4. ¿es posible establecer una comparación válida en cuanto a las prestaciones de un mismo sistema utilizado dos benchmarks distintos (en este caso NovaBench y estimadores de SPEC)? Justifica la respuesta

Establecer una comparación válida entre los resultados de dos benchmarks diferentes, como NovaBench y los estimadores de SPEC, es complejo y puede ser problemático. Esto se debe a que los benchmarks utilizan escalas de puntuación y metodologías distintas, lo que dificulta la comparación directa de los resultados. Además, las métricas de rendimiento en los dos benchmarks pueden estar basadas en diferentes cargas de trabajo y conjuntos de pruebas.



3. CONCLUSIONES PERSONALES

Esta práctica proporciona una visión clara de los benchmarks y las métricas utilizadas para evaluar el rendimiento de sistemas informáticos, centrándose en el SPEC CPU 2017 y NovaBench como ejemplos. Estos benchmarks miden el rendimiento de CPU en una amplia gama de aplicaciones y operaciones.

Las métricas, como SPECrate para operaciones de coma flotante e integrales en SPEC CPU 2017 y los puntajes NovaBench, permiten a los usuarios comparar y evaluar el rendimiento de diferentes sistemas. Sin embargo, es fundamental comprender que las métricas de diferentes benchmarks no siempre son directamente comparables debido a las diferencias en las cargas de trabajo, las escalas de puntuación y las unidades utilizadas.

La conversión de métricas entre diferentes benchmarks puede ser compleja y, en algunos casos, poco precisa. Por lo tanto, al comparar el rendimiento de sistemas utilizando diferentes benchmarks, es esencial considerar las limitaciones y la necesidad de interpretar los resultados con cautela.

En conclusión, la elección del benchmark y la comprensión de sus métricas son aspectos cruciales al evaluar el rendimiento de sistemas informáticos. La comparación de sistemas a través de diferentes benchmarks puede proporcionar información valiosa, pero debe realizarse con pleno conocimiento de las diferencias en las métricas y las limitaciones inherentes a dichas comparaciones.



4. BIBLIOGRAFÍA

- 1. Consultar los apuntes de la asignatura Arquitectura e Ingeniería de Computadores
- 2. Consultar la documentación de SPEC: https://www.spec.org
- 3. Consulta de documentación e instalación de la aplicación de NovaBench: https://novabench.com